

Dokumentacja Specyfikacji Wymagań

System analizy opinii klientów hoteli

Projekt: “*System analizy opinii klientów hoteli*” (Przetwarzanie tekstu, analiza wydźwięku, modelowanie tematów LDA, korelacje terminów oraz klastrowanie k-means)

Wersja dokumentu: 1.0

Data: 4 czerwca 2026 r.

Autorzy: Ciborowska Hanna, Nagorna Maryna, Kowzan Eliza

1. Wprowadzenie

Niniejszy dokument opisuje specyfikację wymagań dla skryptu R, który realizuje pełną analizę text mining, modelowanie tematów oraz analizę sentymentu na podstawie zawartości pliku *tripadvisor_hotel_reviews.csv*. System łączy techniki tradycyjnego czyszczenia tekstu i tokenizacji z oceną sentymentu przy użyciu słowników dostępnych w pakiecie *tidytext* (Bing, NRC). Dodatkowo aplikacja wykorzystuje algorytmy uczenia nienadzorowanego (LDA oraz K-Means) do automatycznej segmentacji opinii i wykrywania wątków tematycznych, a końcowe wyniki wizualizuje w formie chmury słów, wykresów statystycznych oraz automatycznego raportu HTML z opcją pokazywania/ukrywania kodu.

2. Cele systemu

- **Wczytanie i przygotowanie danych:**
 - Wczytanie lokalnego pliku *tripadvisor_hotel_reviews.csv* z wymuszeniem kodowania znaków UTF-8.
 - Zmiana nazw oryginalnych kolumn (*Review*, *Rating*) na ujednolicone zmienne robocze oraz odfiltrowanie pustych rekordów.
- **Przetwarzanie i oczyszczanie tekstu:**
 - Przekształcenie danych do obiektu klasy *VCorpus*.
 - Usunięcie liczb, interpunkcji, białych znaków oraz oczyszczenie tekstu z pozostałości adresów URL, tagów HTML i znaków specjalnych za pomocą wyrażeń regularnych (*gsub*).
 - Wykluczenie standardowej listy stop-słów dla języka angielskiego oraz autorskiej listy słów specyficznych dla branży hotelarskiej.
- **Eksploracyjna analiza danych (EDA):**
 - Zliczenie globalnych częstości występowania słów i identyfikacja 20 najpopularniejszych terminów.
 - Obliczenie zaawansowanych wag statystycznych TF-IDF dla słów w dokumentach.
- **Analiza sentymentu i emocji:**
 - Przeprowadzenie binarnej analizy wydźwięku (słowa pozytywne/negatywne) z

wykorzystaniem słownika Bing.

- Przeprowadzenie analizy profilu emocjonalnego opinii z wykorzystaniem słownika NRC.
- Zbadanie i zwizualizowanie relacji między strukturą sentymentu a przyznaną przez klienta oceną hotelu (*Rating*).
- **Uczenie nienadzorowane i analiza relacji:**
 - Wyznaczanie statystycznych korelacji (asocjacji) współwystępowania kluczowych słów branżowych w korpusie.
 - Wykrywanie ukrytych wątków tematycznych za pomocą probabilistycznego modelowania tematów LDA (dla liczby tematów $k=4$).
 - Segmentacja przestrzeni wektorowej opinii na 4 rozłączne grupy za pomocą algorytmu K-Means na zredukowanej losowo próbie dokumentów.
- **Wizualizacja i raportowanie:**
 - Prezentacja wyników za pomocą chmury słów (*wordcloud*) oraz różnorodnych wykresów biblioteki *ggplot2*.
 - Automatyczny zapis wszystkich wygenerowanych wykresów do plików formatu PNG w katalogu roboczym.
 - Kompilacja całości kodu i wyników do estetycznego, menedżerskiego raportu w formacie HTML.

3. Wymagania funkcjonalne

- **Wczytywanie i transformacja struktury danych:**
 - Skrypt powinien wczytywać dane w trybie tekstowym bez automatycznej konwersji na czynniki (*stringsAsFactors = FALSE*).
 - Skrypt powinien usuwać puste opnie oraz automatycznie nadawać unikalny identyfikator numeryczny (*document_id*) dla każdego wiersza.
- **Zaawansowany preprocessing lingwistyczny:**
 - Skrypt powinien normalizować tekst poprzez zamianę wszystkich liter na małe.
 - Skrypt powinien usuwać adresy URL, ukośniki, znaki @, ~, | oraz błędne artefakty kodowania (np. *â€*).
 - Skrypt powinien umożliwiać rozszerzanie standardowych słów zatrzymujących o autorską, zdefiniowaną listę 34 stopwords (np. *hotel, room, stay, night, advisor*).
- **Generowanie macierzy i redukcja wymiarów:**
 - Skrypt powinien tworzyć macierze częstości typu *TermDocumentMatrix* oraz *DocumentTermMatrix*.
 - Skrypt powinien obowiązkowo filtrować słowa rzadkie za pomocą funkcji *removeSparseTerms* z parametrem progu rzadkości równym 0.99, w celu zapewnienia stabilności wydajnościowej.
- **Słownikowa analiza wydźwięku (*tidytext*):**

- Skrypt powinien przeprowadzać tokenizację tekstu do formy pojedynczych słów (*tidy tokens*) z jednoczesnym pominięciem stop-słów.
- Skrypt powinien dopasowywać tokeny do binarnego słownika Bing i wyznaczać sumaryczną liczbę słów pozytywnych oraz negatywnych.
- Skrypt powinien umożliwiać wyodrębnienie 15 najczęstszych słów nacechowanych emocjonalnie w podziale na pozytywne i negatywne.
- Skrypt powinien dopasowywać tokeny do słownika NRC i zliczać wystąpienia słów w ramach przypisanych kategorii emocjonalnych.
- **Analiza statystyczna, asocjacje i modelowanie:**
 - Skrypt powinien wyznaczać surowe częstości słów oraz średnie wartości wag TF-IDF, sortując wyniki malejąco.
 - Skrypt powinien obliczać korelacje terminów za pomocą funkcji *findAssocs* dla wybranych słów kluczowych (*service, staff, clean, location, breakfast, dirty*) z minimalnym progiem korelacji równym 0.20.
 - Skrypt powinien realizować proces modelowania tematów LDA dla k=4 tematów, usuwając uprzednio z macierzy puste dokumenty.
 - Skrypt powinien wyodrębniać 10 najważniejszych słów o najwyższym współczynniku ważności Beta dla każdego z 4 tematów LDA.
- **Klastrowanie K-Means:**
 - Skrypt powinien dokonywać podziału opinii na k=4 klastry na podstawie wartości liczbowych macierzy DTM.
 - Skrypt powinien generować tekstowe podsumowanie każdego klastra, zawierające jego liczebność oraz top 5 najchętniej występujących w nim słów.
- **Eksport i raportowanie wyników:**
 - Skrypt powinien zapisywać surowe tabele wynikowe do plików tekstowych formatu CSV w katalogu roboczym.
 - Skrypt powinien generować wykresy z wykorzystaniem motywów graficznych *theme_minimal()* oraz *theme_gdocs()*.

4. Wymagania niefunkcjonalne

- **Wydajność i ochrona pamięci RAM:**
 - Z uwagi na krytyczne obciążenie procesora, skrypt świadomie pomija procedurę uzupełniania rdzeni słów (*stemCompletion*), operując bezpośrednio na oczyszczonym korpusie tekstowym.
 - Przed uruchomieniem algorytmu klastrowania K-Means, skrypt musi automatycznie ograniczyć wielkość macierzy za pomocą próbkowania losowego do maksymalnie N=1000 dokumentów, chroniąc system przed przepełnieniem pamięci RAM.
 - Skrypt przed uruchomieniem modelowania LDA oraz K-Means musi

bezwzględnie usunąć z macierzy matematycznej wszystkie puste wiersze (dokumenty o zerowej liczbie słów), aby zapobiec awarii algorytmów.

- **Stabilność probabilistyczna (Odtwarzalność):**
 - Wszystkie procedury oparte na operacjach losowych (generowanie chmury słów, próbkowanie do klastrowania, inicjalizacja centrów K-Means oraz algorytm LDA) muszą posiadać zdefiniowane na sztywno ziarno generatora liczb pseudolosowych (*set.seed(123)* lub *set.seed(1234)*), co gwarantuje identyczność wyników przy każdym uruchomieniu raportu.
- **Kompatybilność środowiskowa:**
 - Skrypt musi być w pełni kompatybilny i wykonywalny w środowisku RStudio na systemach operacyjnych Windows, macOS oraz Linux.
 - Skrypt opiera się na stabilnych, ściśle określonych zewnętrznych bibliotekach: *tm*, *tidyverse*, *tidytext*, *textdata*, *wordcloud*, *RColorBrewer*, *ggplot2*, *ggthemes*, *SnowballC*, *topicmodels*, *factoextra*, *cluster* oraz *DT*.
- **Czytelność i struktura kodu źródłowego:**
 - Kod źródłowy musi posiadać przejrzystą strukturę sekwencyjną, wyraźnie wydzieloną za pomocą profesjonalnych znaczników sekcji środowiska RStudio (*# NAZWA SEKCJI ----*).
 - Każda operacja musi być opatrzona komentarzem technicznym, wskazującym cel transformacji lub przeznaczenie użytej kolumny.

5. Interfejsy użytkownika

- **Wejście:**
 - Lokalny, tabelaryczny plik danych *tripadvisor_hotel_reviews.csv* umieszczony bezpośrednio w katalogu roboczym (ścieżka relatywna).
 - Pobierane w tle, wbudowane słowniki bazy *tidytext/textdata* (Bing oraz NRC).
- **Wyjście:**
 - Konsola CLI środowiska RStudio wyświetlająca podsumowania liczbowe, wymiary macierzy oraz tabele strukturalne.
 - Wykresy w panelu *Plots* oraz automatycznie zapisane pliki graficzne PNG o zdefiniowanych proporcjach.
 - Raport menedżerski w formacie HTML generowany za pomocą silnika RMarkdown, oparty na czytelnym motywie wizualnym *readable*, zawierający zautomatyzowany, pływający spis treści (*toc_float*) oraz globalną funkcję zwijania i rozwijania bloków kodu źródłowego (*code_folding: show*).

6. Wymagania dotyczące danych i słownictwo dokumentacji

- **Wymagania dotyczące danych:**
 - Skrypt przetwarza i analizuje wyłącznie teksty opinii napisane w języku

angielskim.

- Skrypt zakłada, że oceny satysfakcji klientów przyjmują wyłącznie wartości numeryczne, całkowite w sztywnym zakresie od 1 do 5.
- Skrypt nie obsługuje zewnętrznych słowników przekazywanych w plikach tekstowych .CSV – bazuje całkowicie na strukturach ładowanych bezpośrednio z pamięci pakietu tekstowego.

- **Słownictwo dokumentacji:**

- **VCorpus (Volatile Corpus):** ulotny korpus tekstowy, wbudowana w pakiet **tm** struktura danych przechowująca zbiór dokumentów w pamięci RAM komputera.
- **DocumentTermMatrix (DTM):** macierz matematyczna, w której wiersze reprezentują poszczególne recenzje, kolumny to unikalne słowa, a wartości w komórkach określają częstość danego słowa w danej opinii.
- **TF-IDF:** statystyczna miara ważenia tekstu, która ocenia znaczenie słowa w kontekście całej bazy opinii (promuje słowa rzadkie i unikalne, obniżając wagę słów powszechnych).
- **Słownik Bing:** klasyczny słownik sentymentu przypisujący słowom sztywne, binarne kategorie: "positive" (pozytywne) lub "negative" (negatywne).
- **Słownik NRC:** wielowymiarowy słownik przypisujący pojedynczym słowom konkretne kategorie emocjonalne (np. złość, strach, radość, zaufanie, smutek) oraz ogólny afekt (pozytywny/negatywny).
- **LDA (Latent Dirichlet Allocation):** probabilistyczny model nienadzorowanego uczenia maszynowego, służący do podziału tekstów na ukryte tematy poprzez analizę prawdopodobieństwa współwystępowania wyrazów.
- **Współczynnik Beta (\$\beta\$):** parametr modelu LDA określający prawdopodobieństwo przynależności konkretnego słowa do danego tematu (im wyższa Beta, tym słowo lepiej definiuje dany temat).
- **K-Means (Algorytm K-Średnich):** metoda nienadzorowanej segmentacji, dzieląca wybraną próbkę recenzji na 4 odrębne, zwarte grupy (klastry) o zbliżonej charakterystyce słownictwa.

7. Przypadki użycia (use cases)

- **Użytkownik:**

- Wczytuje plik tabelaryczny z opiniami do katalogu programu.
- Uruchamia procedurę automatycznego renderowania raportu (*Knit HTML*).
- Analizuje końcowy, sformatowany dokument HTML, filtrując widoczność kodu źródłowego według potrzeb.

- **Skrypt/system:**

- Wczytuje dane wejściowe i mapuje strukturę kolumn na zmienne tekstowe i numeryczne.

- Czyści dane tekstowe z nieczystości lingwistycznych, adresów URL i znaków specjalnych za pomocą potoków *gsub*.
- Filtruje słownictwo ze standardowych oraz dedykowanych stop-słów.
- Konstruuje matematyczne macierze DTM/TDM oraz redukuje ich wymiar poprzez usuwanie słów rzadkich.
- Wyznacza globalne top listy wyrazów oraz wartości wag TF-IDF.
- Przeprowadza proces dopasowywania słów do struktur słownikowych Bing i NRC, wyliczając statystyki sentymentu.
- Zestawia udziały procentowe emocji z ocenami gwiazdkowymi wystawionymi przez użytkowników.
- Wyznacza korelacje wokół zdefiniowanych słów kluczowych.
- Dokonuje ekstrakcji tematów LDA oraz próbkuje macierz do obliczeń klastrowania K-Means.
- Zapisuje tabele CSV, generuje finalne grafiki PNG oraz kompiluje estetyczny plik raportu HTML.

Testowe przypadki użycia:

- **Test kompletności pliku:** Uruchomienie skryptu przy obecnym pliku *tripadvisor_hotel_reviews.csv* w celu weryfikacji poprawnego przejścia całego potoku analitycznego.
- **Test rozkładu ocen:** Weryfikacja, czy skrypt poprawnie zlicza opinie dla każdej z ocen w skali 1-5 i poprawnie eksportuje tabelę do pliku *wyniki_01_rozklad_ocen.csv*.
- **Test stabilności losowej:** Dwukrotne uruchomienie skryptu od zera w celu sprawdzenia, czy wygenerowane chmury słów, wykresy klastrów K-Means oraz rozkłady tematów LDA są idealnie tożsame (weryfikacja działania instrukcji *set.seed*).
- **Test czyszczenia znaków specjalnych:** Weryfikacja, czy po przejściu procedur preprocessingowych z recenzji całkowicie zniknęły linki URL, znaki interpunkcyjne oraz pozostałości błędnego kodowania (np. *â€œ*).
- **Test redukcji wymiarowości opinii:** Sprawdzenie, czy po uruchomieniu funkcji *sample()* dla modułu K-Means, wielkość próby do analizy klastrowej wynosi dokładnie 1000 dokumentów.

8. Scenariusze użytkownika (user stories)

Scenariusz 1: Identyfikacja kluczowych tematów niezadowolenia gości

- **Jako:** Dyrektor generalny hotelu.
- **Chcę:** Automatycznie pogrupować tysiące recenzji w 4 główne wątki tematyczne i sprawdzić przypisane do nich słowa o najwyższym współczynniku Beta.
- **Aby:** Szybko dowiedzieć się, jakie obszary hotelu (np. obsługa, czystość, jedzenie) są

najczęściej poruszane przez klientów, bez konieczności ręcznego czytania każdej opinii.

Kryteria akceptacji:

- Skrypt poprawnie usuwa puste wiersze i bezbłędnie buduje model LDA dla 4 tematów.
- System generuje przejrzysty wykres panelowy przedstawiający po 10 najważniejszych słów dla każdego tematu.
- Wyniki są zapisywane do zewnętrznego pliku *wyniki_08_lda_top_slowa.csv*.

Scenariusz 2: Analiza korelacji emocjonalnych wokół jakości obsługi

- **Jako:** Menedżer ds. relacji z klientami.
- **Chcę:** Przeanalizować recenzje za pomocą słownika emocji NRC oraz zbadać udziały słów pozytywnych/negatywnych w zależności od przyznanych gwiazdek.
- **Aby:** Zrozumieć strukturę emocjonalną gości i zweryfikować, czy klienci dający niskie oceny używają unikalnych słów negatywnych związanych np. z czystością lub zachowaniem personelu.

Kryteria akceptacji:

- System generuje wykres słupkowy obrazujący rozkład 10 kategorii emocji słownika NRC.
- Skrypt tworzy wykres skumulowany prezentujący zmianę proporcji słów pozytywnych i negatywnych (Bing) dla każdej z pięciu grup ocen (*Rating 1-5*).
- Wykresy zostają automatycznie wyeksportowane do plików PNG o nazwach *wykres_07_emocje_nrc.png* oraz *wykres_08_sentyment_wedlug_oceny.png*.

Scenariusz 3: Sprawne uruchomienie i przegląd techniczny projektu

- **Jako:** Wykładowca / Audytor kodu.
- **Chcę:** Pobrać skrypt, umieścić plik CSV w folderze i uruchomić proces kompilacji raportu, mając możliwość wygodnego zwijania sekcji z kodem źródłowym podczas analizy wyników.
- **Aby:** Sprawnie ocenić poprawność implementacji algorytmów tekstowych oraz sprawdzić jakość wygenerowanych wykresów bez zaburzania estetyki dokumentu nadmiarem kodu.

Kryteria akceptacji:

- Skrypt wykorzystuje relatywne odwołanie do pliku danych (*file_name <- "tripadvisor_hotel_reviews.csv"*), co pozwala na uruchomienie go na dowolnym komputerze.
- Raport HTML ładuje się z motywem wizualnym *readable* oraz posiada działający,

boczny spis treści.

- Każdy blok kodu R w wygenerowanym dokumencie HTML posiada działający przycisk *Hide/Show*, umożliwiający dynamiczne sterowanie widocznością kodu.

9. Podział zakresu pracy członków zespołu

Projekt został zrealizowany wspólnie przez zespół 3-osobowy, a zadania zostały podzielone sekwencyjnie i modułowo, zgodnie ze specjalizacjami członków zespołu:

- **Ciborowska Hanna**
 - **Kod źródłowy R:** Implementacja Sekcji 1, 2, 3 oraz 4 (Wczytanie danych, statystyki i rozkład ocen, utworzenie korpusu tekstowego, zaawansowane czyszczenie tekstu wyrażeniami regularnymi oraz budowa macierzy BoW: TDM i DTM).
 - **Dokumentacja SRS:** Opracowanie wprowadzenia (Sekcja 1), celów systemu (Sekcja 2), wymagań dotyczących danych oraz słownictwa dokumentacji (Sekcja 6).
 - **Zadania organizacyjne:** Koordynacja repozytorium GitHub, przygotowanie i mapowanie pliku wejściowego CSV.
- **Nagorna Maryna**
 - **Kod źródłowy R:** Implementacja Sekcji 5, 6, 7, 8 oraz 9 (Analiza częstości słów, generowanie chmury słów, podejście TF-IDF, słownikowa analiza sentymentu Bing oraz analiza emocji słownikiem NRC).
 - **Dokumentacja SRS:** Opracowanie kompletnej listy wymagań funkcjonalnych i нефункциональных (Sekcja 3 i 4) oraz interfejsów użytkownika (Sekcja 5).
 - **Zadania organizacyjne:** Nadzór nad prawidłowym ładowaniem wbudowanych słowników tekstowych oraz walidacja eksportu plików wynikowych CSV.
- **Kowzan Eliza**
 - **Kod źródłowy R:** Implementacja Sekcji 10, 11, 12 oraz 13 (Analiza relacji sentymentu do ocen hotelu, obliczanie asocjacji słownych, probabilistyczne modelowanie tematów LDA oraz klastrowanie algorytmem K-Means z próbkowaniem).
 - **Dokumentacja SRS:** Opracowanie struktury przypadków użycia i testów (Sekcja 7) oraz scenariuszy użytkownika / kryteriów akceptacji User Stories (Sekcja 8).
 - **Zadania organizacyjne:** Konfiguracja parametrów środowiskowych i wizualnych RMarkdown (motyw *readable*, pływający spis treści, automatyczne zwijanie kodu) oraz kompilacja końcowego raportu do formatu HTML.